

Regresión Lineal Múltiple: Estimación

Clase 17

Nicolás Mejía M.
n.mejia10@uniandes.edu.co

Probabilidad y Estadística II
Departamento de Ingeniería Industrial
Universidad de Los Andes, Bogotá, Colombia

2020-19

Outline

- 1 Remember, Remember...
- 2 Regresión Lineal Múltiple
 - Planteamiento
 - Estimación
 - Propiedades del estimador

Motivación

Que se logra con un modelo de regresión?

- ① **Explicar:** Se pueden responder preguntas científicas (parecidas al diseño de experimentos) sobre la influencia de las variables independientes sobre la respuesta:
 - Aumenta el salario de un egresado obtener un mejor promedio académico?
 - Vale la pena estudiar más para el parcial?
- ② **Predecir:** Se puede predecir el comportamiento de la variable de respuesta si se fijan los niveles de X :
 - Si mi promedio es 3.99, qué puedo esperar de mi salario?
 - Qué pasará si estudio solamente 4 horas para el próximo parcial?
- ③ **Precisión en Inferencia:** Parecido al diseño de experimentos, al tener en cuenta el efecto de las X 's, se reduce la varianza, con lo cual la inferencia acerca de Y es más precisa (con más potencia).
 - Al hacer un prueba para saber si mi salario será mayor a \$2 millones, esta será mucho más exacta a respuesta si conozco mi promedio.

Planteamiento

Vamos a concentrarnos hoy en el caso en que **solo se tiene una variable explicativa**. Este caso se denomina el modelo de regresión lineal simple:

$$Y = \beta_0 + \beta_1 X_1 + \epsilon$$

Donde $\epsilon \sim_{iid} N(0, \sigma^2)$. Bajo estos supuestos se considera que:

$$Y|X_1 \sim \text{Normal}(\beta_0 + \beta_1 X_1, \sigma^2)$$

Es decir, la media de Y dado X es $E(Y|X) = \beta_0 + \beta_1 X_1$, luego:

- β_0 es el valor esperado de Y dado un valor nulo de la variable X
- β_1 es el aumento en Y , dado un aumento de 1 en X

Outline

1 Remember, Remember...

2 Regresión Lineal Múltiple

- Planteamiento
- Estimación
- Propiedades del estimador

Planteamiento

En un modelo de regresión lineal se plantea la relación:

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k + \epsilon$$

Donde $\epsilon \sim_{iid} N(0, \sigma^2)$, el cual corresponde al **error** aleatorio en la observación, que es también homocedástico. Bajo estos supuestos se considera que:


$$Y|X_1, \dots, X_k \sim \text{Normal}(\beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k, \sigma^2)$$

Es decir, la media de Y dado X_1, \dots, X_k se plantea como una relación lineal $E(Y|X_1, \dots, X_k) = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$, luego:

- β_0 es el valor esperado de Y dado un valor nulo de las X 's
- β_j es el aumento en Y , dado un aumento de 1 en X_j

Planteamiento

Si se tienen 2 variables explicativas, gráficamente se tendría una situación de este estilo:



El error aleatorio simplemente describe las desviaciones sobre la recta que no se pueden explicar por medio de X .

Outline

- 1 Remember, Remember...
- 2 Regresión Lineal Múltiple
 - Planteamiento
 - Estimación
 - Propiedades del estimador

Estimación

En la práctica, **no tenemos conocimiento de los coeficientes $\beta_1, \beta_1, \dots, \beta_k$ por tanto debemos estimarlos.**

Dada una muestra de n datos, que corresponden a tuplas de observaciones de la variable de interés Y , y las variables explicativas X_1, \dots, X_k :

i	Y	X_1	...	X_j	...	X_k
1	Y_1	X_{11}	...	X_{j1}	...	X_{k1}
2	Y_2	X_{12}	...	X_{j2}	...	X_{k2}
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
i	Y_i	X_{1i}	...	X_{ji}	...	X_{ki}
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
n	Y_n	X_{1n}	...	X_{jn}	...	X_{kn}

El objetivo es tratar de recrear la relación entre ellas.

Estimación

Escribiendo el modelo para cada observación se tendría que:

$$Y_1 = \beta_0 + \beta_1 X_{11} + \cdots + \beta_k X_{k1} + \epsilon$$

$$Y_2 = \beta_0 + \beta_1 X_{12} + \cdots + \beta_k X_{k2} + \epsilon$$

$$\vdots$$

$$Y_n = \beta_0 + \beta_1 X_{1n} + \cdots + \beta_k X_{kn} + \epsilon$$

donde $\epsilon \sim N(0, \sigma^2)$ y $\text{cov}(\epsilon_i, \epsilon_j) = 0, i \neq j$

Estimación

Lo cual en formato matricial quedaría:

$$\begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} = \begin{bmatrix} 1 & X_{11} & \cdots & X_{k1} \\ 1 & X_{12} & \cdots & X_{k2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1n} & \cdots & X_{kn} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon$$

$$\text{donde } \mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}, \mathbf{X} = \begin{bmatrix} 1 & X_{11} & \cdots & X_{k1} \\ 1 & X_{12} & \cdots & X_{k2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1n} & \cdots & X_{kn} \end{bmatrix}, \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} \text{ y } \epsilon = \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

Estimación

Los supuestos en formato matricial quedan:

$$E(\epsilon) = \begin{bmatrix} E(\epsilon_1) \\ E(\epsilon_2) \\ \vdots \\ E(\epsilon_n) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = 0$$

$$Var(\epsilon) = \begin{bmatrix} Var(\epsilon_1) & Cov(\epsilon_1, \epsilon_2) & \cdots & Cov(\epsilon_1, \epsilon_n) \\ Cov(\epsilon_1, \epsilon_2) & Var(\epsilon_2) & \cdots & Cov(\epsilon_2, \epsilon_n) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(\epsilon_1, \epsilon_n) & Cov(\epsilon_2, \epsilon_n) & \cdots & Var(\epsilon_n) \end{bmatrix}$$

$$= \begin{bmatrix} \sigma^2 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2 \end{bmatrix} = \sigma^2 \mathbf{I}$$

Estimación

Cómo se hace el ajuste? Mínimos Cuadrados Ordinarios

El hiperplano **ajustado** se puede denotar como

$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \hat{\beta}_k X_k$, luego el error de estimación es $e_i = Y_i - \hat{Y}_i$.

La idea es minimizar la suma de cuadrados del error:

$$SSE = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \hat{\beta}_k X_k)^2$$

La suma simplemente agrega el error de todas las observaciones, y el cuadrado hace desaparecer el signo para así minimizar la magnitud del error.

Estimación

Cómo hallamos el mínimo? Derivando, igualando a 0 y despejando

Las ecuaciones normales

$$\frac{\partial SSE}{\partial \beta_0} = -2 \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \cdots - \hat{\beta}_k X_{ki}) = 0$$

$$\frac{\partial SSE}{\partial \beta_1} = -2 \sum_{i=1}^n X_{1i} (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \cdots - \hat{\beta}_k X_{ki}) = 0$$

$$\vdots$$

$$\frac{\partial SSE}{\partial \beta_k} = -2 \sum_{i=1}^n X_{ki} (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \cdots - \hat{\beta}_k X_{ki}) = 0$$

Estimación

Reorganizando el sistema queda como:

Las ecuaciones normales

$$\sum_{i=1}^n Y_i - \sum_{i=1}^n \hat{\beta}_0 - \sum_{i=1}^n \hat{\beta}_1 X_{1i} - \cdots - \sum_{i=1}^n \hat{\beta}_k X_{ki} = 0$$

$$\sum_{i=1}^n X_{1i} Y_i - \sum_{i=1}^n \hat{\beta}_0 X_{1i} - \sum_{i=1}^n \hat{\beta}_1 X_{1i} X_{1i} - \cdots - \sum_{i=1}^n \hat{\beta}_k X_{1i} X_{ki} = 0$$

$$\vdots$$

$$\sum_{i=1}^n X_{ki} Y_i - \sum_{i=1}^n \hat{\beta}_0 X_{ki} - \sum_{i=1}^n \hat{\beta}_1 X_{ki} X_{1i} - \cdots - \sum_{i=1}^n \hat{\beta}_k X_{ki} X_{ki} = 0$$

Estimación

Reorganizando el sistema queda como:

Las ecuaciones normales

$$\hat{\beta}_0 n + \hat{\beta}_1 \sum_{i=1}^n X_{1i} + \cdots - \hat{\beta}_k \sum_{i=1}^n X_{ki} = \sum_{i=1}^n Y_i$$

$$\hat{\beta}_0 \sum_{i=1}^n X_{1i} + \hat{\beta}_1 \sum_{i=1}^n X_{1i}^2 + \cdots - \hat{\beta}_k \sum_{i=1}^n X_{1i} X_{ki} = \sum_{i=1}^n X_{1i} Y_i$$

$$\vdots$$

$$\hat{\beta}_0 \sum_{i=1}^n X_{ki} + \hat{\beta}_1 \sum_{i=1}^n X_{1i} X_{ki} + \cdots - \hat{\beta}_k \sum_{i=1}^n X_{ki}^2 = \sum_{i=1}^n X_{ki} Y_i$$

Estimación

Matricialmente queda:

$$\begin{bmatrix} n & \sum_{i=1}^n X_{1i} & \sum_{i=1}^n X_{2i} & \cdots & \sum_{i=1}^n X_{ki} \\ \sum_{i=1}^n X_{1i} & \sum_{i=1}^n X_{1i}^2 & \sum_{i=1}^n X_{2i}X_{1i} & \cdots & \sum_{i=1}^n X_{ki}X_{1i} \\ \sum_{i=1}^n X_{2i} & \sum_{i=1}^n X_{1i}X_{2i} & \sum_{i=1}^n X_{2i}^2 & \cdots & \sum_{i=1}^n X_{ki}X_{2i} \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ \sum_{i=1}^n X_{ki} & \sum_{i=1}^n X_{1i}X_{ki} & \sum_{i=1}^n X_{2i}X_{ki} & \cdots & \sum_{i=1}^n X_{ki}^2 \end{bmatrix} \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_k \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n X_{1i}Y_i \\ \sum_{i=1}^n X_{2i}Y_i \\ \vdots \\ \sum_{i=1}^n X_{ki}Y_i \end{bmatrix}$$

Que en nuestras definiciones sería equivalente a:

$$(\mathbf{X}^T \mathbf{X}) \hat{\boldsymbol{\beta}} = \mathbf{X}^T \mathbf{Y}$$

y despejando queda que:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

Estimación

El estimador ya no es una expresión puntual particular, debe encontrarse numéricamente! Importante que recuerden la estructura de las matrices
TODO LO QUE NECESITAN ESTÁ AHÍ:

$$\mathbf{X}^T \mathbf{X} = \begin{bmatrix} n & \sum_{i=1}^n X_{1i} & \sum_{i=1}^n X_{2i} & \cdots & \sum_{i=1}^n X_{ki} \\ \sum_{i=1}^n X_{1i} & \sum_{i=1}^n X_{1i}^2 & \sum_{i=1}^n X_{2i} X_{1i} & \cdots & \sum_{i=1}^n X_{ki} X_{1i} \\ \sum_{i=1}^n X_{2i} & \sum_{i=1}^n X_{1i} X_{2i} & \sum_{i=1}^n X_{2i}^2 & \cdots & \sum_{i=1}^n X_{ki} X_{2i} \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ \sum_{i=1}^n X_{ki} & \sum_{i=1}^n X_{1i} X_{ki} & \sum_{i=1}^n X_{2i} X_{ki} & \cdots & \sum_{i=1}^n X_{ki}^2 \end{bmatrix}$$

$$\mathbf{X}^T \mathbf{Y} = \begin{bmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n X_{1i} Y_i \\ \sum_{i=1}^n X_{2i} Y_i \\ \vdots \\ \sum_{i=1}^n X_{ki} Y_i \end{bmatrix}$$

Outline

1 Remember, Remember...

2 Regresión Lineal Múltiple

- Planteamiento
- Estimación
- Propiedades del estimador

Propiedades del estimador

El estimador de mínimos cuadrados tiene la siguiente **distribución multivariada** (recuerde que es un vector):

$$\hat{\beta} \sim N\left(\beta, \sigma^2(\mathbf{X}^T \mathbf{X})^{-1}\right)$$

es decir, el estimador es Normal, insesgado y consistente.

Teorema de Gauss-Markov

El estimador de mínimos cuadrados es el estimador de **varianza mínima** en la clase de los estimadores lineales insesgados, cuando se satisfacen los supuestos de regresión. En palabras simples, es **el estimador más eficiente**.

Estimación de la varianza

Las expresiones anteriores involucran a σ^2 , luego es necesario estimarlo. Para este punto ya sabemos como!

$$\hat{\sigma}^2 = MSE = \frac{SSE}{gl_E}$$

Ya vimos que el SSE se define como:

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \hat{\beta}_k X_k)^2$$

Luego el total de grados de libertad es $gl_E = n - k - 1 = n - \# \beta_{etas}$.