

# Regresión Lineal Múltiple: Inferencia Estadística

## Clase 18

Nicolás Mejía M.  
n.mejia10@uniandes.edu.co

**Probabilidad y Estadística II**  
**Departamento de Ingeniería Industrial**  
**Universidad de Los Andes, Bogotá, Colombia**

2020-19

- 1 Regresión Lineal Múltiple
  - Planteamiento
  - Estimación
  - Propiedades del estimador
  - Pruebas de Hipótesis
  - Intervalos de Confianza y Predicción

# Planteamiento

En un modelo de regresión lineal se plantea la relación:

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k + \epsilon$$

Donde  $\epsilon \sim_{iid} N(0, \sigma^2)$ , el cual corresponde al **error** aleatorio en la observación, que es también homocedástico. Bajo estos supuestos se considera que:


$$Y|X_1, \dots, X_k \sim \text{Normal}(\beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k, \sigma^2)$$

Es decir, la media de  $Y$  dado  $X_1, \dots, X_k$  se plantea como una relación lineal  $E(Y|X_1, \dots, X_k) = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$ , luego:

- $\beta_0$  es el valor esperado de  $Y$  dado un valor nulo de las  $X$ 's
- $\beta_j$  es el aumento en  $Y$ , dado un aumento de 1 en  $X_j$

# Planteamiento

Si se tienen 2 variables explicativas, gráficamente se tendría una situación de este estilo:



El error aleatorio simplemente describe las desviaciones sobre la recta que no se pueden explicar por medio de  $X$ .

## Planteamiento

En la práctica, **no tenemos conocimiento de los coeficientes  $\beta_1, \beta_1, \dots, \beta_k$**  por tanto **debemos estimarlos**.

Dada una muestra de  $n$  datos, que corresponden a tuplas de observaciones de la variable de interés  $Y$ , y las variables explicativas  $X_1, \dots, X_k$ :

i	$Y$	$X_1$	...	$X_j$	...	$X_k$
1	$Y_1$	$X_{11}$	...	$X_{j1}$	...	$X_{k1}$
2	$Y_2$	$X_{12}$	...	$X_{j2}$	...	$X_{k2}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
i	$Y_i$	$X_{1i}$	...	$X_{ji}$	...	$X_{ki}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	$Y_n$	$X_{1n}$	...	$X_{jn}$	...	$X_{kn}$

El objetivo es tratar de recrear la relación entre ellas.

# Planteamiento

Escribiendo el modelo para cada observación se tendría que:

$$Y_1 = \beta_0 + \beta_1 X_{11} + \cdots + \beta_k X_{k1} + \epsilon$$

$$Y_2 = \beta_0 + \beta_1 X_{12} + \cdots + \beta_k X_{k2} + \epsilon$$

$$\vdots$$

$$Y_n = \beta_0 + \beta_1 X_{1n} + \cdots + \beta_k X_{kn} + \epsilon$$

donde  $\epsilon \sim N(0, \sigma^2)$  y  $\text{cov}(\epsilon_i, \epsilon_j) = 0, i \neq j$

# Planteamiento

Lo cual en formato matricial quedaría:

$$\begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} = \begin{bmatrix} 1 & X_{11} & \cdots & X_{k1} \\ 1 & X_{12} & \cdots & X_{k2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1n} & \cdots & X_{kn} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

$$\mathbf{Y} = \mathbf{X}\beta + \epsilon$$

$$\text{donde } \mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}, \mathbf{X} = \begin{bmatrix} 1 & X_{11} & \cdots & X_{k1} \\ 1 & X_{12} & \cdots & X_{k2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1n} & \cdots & X_{kn} \end{bmatrix}, \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} \text{ y } \epsilon = \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

# Planteamiento

Los supuestos en formato matricial quedan:

$$E(\epsilon) = \begin{bmatrix} E(\epsilon_1) \\ E(\epsilon_2) \\ \vdots \\ E(\epsilon_n) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = 0$$

$$Var(\epsilon) = \begin{bmatrix} Var(\epsilon_1) & Cov(\epsilon_1, \epsilon_2) & \cdots & Cov(\epsilon_1, \epsilon_n) \\ Cov(\epsilon_1, \epsilon_2) & Var(\epsilon_2) & \cdots & Cov(\epsilon_2, \epsilon_n) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(\epsilon_1, \epsilon_n) & Cov(\epsilon_2, \epsilon_n) & \cdots & Var(\epsilon_n) \end{bmatrix}$$

$$= \begin{bmatrix} \sigma^2 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2 \end{bmatrix} = \sigma^2 \mathbf{I}$$



# Outline

- 1 Regresión Lineal Múltiple
  - Planteamiento
  - Estimación
  - Propiedades del estimador
  - Pruebas de Hipótesis
  - Intervalos de Confianza y Predicción

# Estimación

## Cómo se hace el ajuste? Mínimos Cuadrados Ordinarios

El hiperplano **ajustado** se puede denotar como

$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \hat{\beta}_k X_k$ , luego el error de estimación es  $e_i = Y_i - \hat{Y}_i$ .

La idea es minimizar la suma de cuadrados del error:

$$SSE = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \hat{\beta}_k X_k)^2$$

La suma simplemente agrega el error de todas las observaciones, y el cuadrado hace desaparecer el signo para así minimizar la magnitud del error.

# Estimación

Matricialmente queda:

$$\begin{bmatrix} n & \sum_{i=1}^n X_{1i} & \sum_{i=1}^n X_{2i} & \cdots & \sum_{i=1}^n X_{ki} \\ \sum_{i=1}^n X_{1i} & \sum_{i=1}^n X_{1i}^2 & \sum_{i=1}^n X_{2i}X_{1i} & \cdots & \sum_{i=1}^n X_{ki}X_{1i} \\ \sum_{i=1}^n X_{2i} & \sum_{i=1}^n X_{1i}X_{2i} & \sum_{i=1}^n X_{2i}^2 & \cdots & \sum_{i=1}^n X_{ki}X_{2i} \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ \sum_{i=1}^n X_{ki} & \sum_{i=1}^n X_{1i}X_{ki} & \sum_{i=1}^n X_{2i}X_{ki} & \cdots & \sum_{i=1}^n X_{ki}^2 \end{bmatrix} \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_k \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n X_{1i}Y_i \\ \sum_{i=1}^n X_{2i}Y_i \\ \vdots \\ \sum_{i=1}^n X_{ki}Y_i \end{bmatrix}$$

Que en nuestras definiciones sería equivalente a:

$$(\mathbf{X}^T \mathbf{X}) \hat{\boldsymbol{\beta}} = \mathbf{X}^T \mathbf{Y}$$

y despejando queda que:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

# Outline

- 1 Regresión Lineal Múltiple
  - Planteamiento
  - Estimación
  - Propiedades del estimador
  - Pruebas de Hipótesis
  - Intervalos de Confianza y Predicción

# Propiedades del estimador

El estimador de mínimos cuadrados tiene la siguiente **distribución multivariada** (recuerde que es un vector):

$$\hat{\beta} \sim N\left(\beta, \sigma^2(\mathbf{X}^T \mathbf{X})^{-1}\right)$$

es decir, el estimador es Normal, insesgado y consistente.

## Teorema de Gauss-Markov

El estimador de mínimos cuadrados es el estimador de **varianza mínima** en la clase de los estimadores lineales insesgados, cuando se satisfacen los supuestos de regresión. En palabras simples, es **el estimador más eficiente**.

## Estimación de la varianza

Las expresiones anteriores involucran a  $\sigma^2$ , luego es necesario estimarlo. Para este punto ya sabemos como!

$$\hat{\sigma}^2 = MSE = \frac{SSE}{gl_E}$$

Ya vimos que el SSE se define como:

$$SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \hat{\beta}_k X_k)^2$$

Luego el total de grados de libertad es  $gl_E = n - k - 1 = n - \# \beta_{etas}$ .

# Outline

- 1 Regresión Lineal Múltiple
  - Planteamiento
  - Estimación
  - Propiedades del estimador
  - Pruebas de Hipótesis
  - Intervalos de Confianza y Predicción

# Pruebas de Hipótesis: Significancia Individual

Una de las preguntas más importantes que queremos contestar, es **Para saber si la variable  $X_j$  es o no relevante para explicar el comportamiento de  $Y$ .** En nuestra notación, esto es equivalente a preguntar si:

$H_0$  : La Variable  $X_j$  NO es significativa  $\Leftrightarrow \beta_j = 0$

$H_1$  : La Variable  $X_j$  SI es significativa  $\Leftrightarrow \beta_j \neq 0$

$$t = \frac{\hat{\beta}_j}{\sqrt{\hat{Var}(\hat{\beta}_j)}} \sim t_{glE}$$

donde  $\hat{Var}(\hat{\beta}_j)$  es la  $j$ -ésima posición de la diagonal de la matriz  $MSE(\mathbf{X}^T \mathbf{X})^{-1}$



# Pruebas de Hipótesis: Significancia Global

La pregunta anterior prueba una a una las variables incorporadas al modelo. ¿Qué sucede si queremos preguntar por el global del modelo? Es decir, se quiere probar **si las variables como grupo sirven o no para explicar el comportamiento de  $Y$** .

$H_0$  : El Modelo NO es significativo  $\Leftrightarrow \beta_1 = \beta_2 = \dots = \beta_k = 0$

$H_1$  : El Modelo SI es significativo  $\Leftrightarrow$  Algún  $\beta_j \neq 0, j \in \{1, \dots, k\}$

En forma general, esta hipótesis dice si el modelo con las  $X$ 's que se incluyeron, sirven o no para predecir  $Y$ .

**¿No les resulta familiar la hipótesis?**

# Pruebas de Hipótesis: Significancia Global

Efectivamente, es muy parecida al hipótesis del ANOVA! Vamos a construir su equivalente para regresión. Para eso definimos:

## Las sumas de cuadrados

$$\text{Suma de cuadrados total } SST = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \mathbf{Y}^T \mathbf{Y} - n\bar{Y}^2$$

$$\text{Suma de cuad. de la regresión } SSR = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = \hat{\beta}^T (\mathbf{X}^T \mathbf{Y}) - n\bar{Y}^2$$

$$\text{Suma de cuadrados del la error } SSE = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \mathbf{Y}^T \mathbf{Y} - \hat{\beta}^T (\mathbf{X}^T \mathbf{Y})$$

# Pruebas de Hipótesis: Significancia Global

La interpretación de las sumas de cuadrados es la misma:

- SST es la variación total observada en el comportamiento de Y.
- SSR es la variación de Y que es explicada por el modelo de regresión, es decir, por la inclusión de las variables explicativas.
- SSE es la parte de la variación total de Y, que no se puede explicar con el modelo de regresión.

Ecuación fundamental de las sumas de cuadrados

$$SST = SSR + SSE$$

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

# Pruebas de Hipótesis: Significancia Global

Recordando que  $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \beta_k X_k$ , los grados de libertad son:

Grados de libertad

$$SST = \sum_{i=1}^n (Y_i - \bar{Y})^2 \Rightarrow gl_T = n - 1$$

$$SSR = \sum_{i=1}^n \left( \hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \beta_k X_k - \bar{Y} \right)^2 \Rightarrow gl_R = k$$

$$SSE = \sum_{i=1}^n \left( Y_i - \hat{\beta}_0 + \hat{\beta}_1 X_1 + \cdots + \beta_k X_k \right)^2 \Rightarrow gl_E = n - k - 1$$

$$gl_T = gl_R + gl_E$$

# Pruebas de Hipótesis: Significancia Global

Por lo tanto el estadístico  $F$  queda:

$H_0$  : El Modelo NO es significativo  $\Leftrightarrow \beta_1 = \beta_2 = \dots = \beta_k = 0$

$H_1$  : El Modelo SI es significativo  $\Leftrightarrow$  Algún  $\beta_j \neq 0, j \in \{1, \dots, k\}$

$$F = \frac{\frac{SSR}{k}}{\frac{SSE}{n-k-1}} \sim F_{k,n-k-1}$$

$$RH_0 \Leftrightarrow F \geq F_{1-\alpha,k,n-k-1}$$

## Nota

Si bien no se menciona, los pasos intermedios que hicimos cuando vimos la prueba  $F$  para DOE, así como la aplicación del teorema de Cochran, se mantienen para la equivalente aquí en regresión.

## Combinaciones lineal de betas

Algunas cuentas de interés se pueden dar en una expresión de este estilo:

$$\theta = \sum_{j=0}^k c_j \beta_j$$

donde los  $c_j$  son constantes fijas, asociadas a costos, ingresos, etc. El objetivo es realizar procedimientos de inferencia estadística (pruebas de hipótesis e intervalos de confianza).

El **estimador natural** de esta expresión estaría dado por:

$$\hat{\theta} = \sum_{j=0}^k c_j \hat{\beta}_j = \mathbf{c}^T \hat{\boldsymbol{\beta}}$$

donde  $\mathbf{c}^T = (c_0, c_1, \dots, c_k)$  es un vector

# Combinaciones lineal de betas

De esto se deduce que:

$$\hat{\theta} = \sum_{j=0}^k c_j \hat{\beta}_j \sim N \left( \sum_{j=0}^k c_j \beta_j, \sum_{j=0}^k c_j^2 \text{Var}(\hat{\beta}_j) + 2 \sum_{j=0}^k \sum_{i=0}^{j-1} c_i c_j \text{Cov}(\hat{\beta}_i, \hat{\beta}_j) \right)$$

o matricialmente

$$\hat{\theta} = \mathbf{c}^T \hat{\beta} \sim N \left( \mathbf{c}^T \beta, \mathbf{c}^T \text{Var}(\hat{\beta}) \mathbf{c} \right)$$

donde  $\text{Var}(\hat{\beta}) = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$

# Combinaciones lineal de betas

Luego estimando la varianza se tiene que:

Pruebas de hipótesis

$$t = \frac{\mathbf{c}^T \hat{\beta} - \theta_0}{\sqrt{\mathbf{c}^T \hat{Var}(\hat{\beta}) \mathbf{c}}} \sim t_{gIE}$$

Intervalos de Confianza

$$IC_{1-\alpha}(\theta) = \mathbf{c}^T \hat{\beta} \pm t_{1-\alpha/2, gIE} \sqrt{\mathbf{c}^T \hat{Var}(\hat{\beta}) \mathbf{c}}$$

donde  $\hat{Var}(\hat{\beta}) = MSE(\mathbf{X}^T \mathbf{X})^{-1}$



# Outline

- 1 Regresión Lineal Múltiple
  - Planteamiento
  - Estimación
  - Propiedades del estimador
  - Pruebas de Hipótesis
  - Intervalos de Confianza y Predicción

# Intervalos de Confianza y Predicción

Otra pregunta de interés, está asociada a si se desea conocer **si el valor medio de  $Y$  toma un valor particular, dado cierto valor de  $X$** . El mejor estimador de  $E(Y|X)$  está dado por la recta de regresión:

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_k x_k = \mathbf{x}^T \hat{\beta}$$

donde  $\mathbf{x}^T = c(1, x_1, \cdots, x_k)$ . Por lo que ya se dedujo del caso anterior, se tiene que:

$$\hat{Y} = \mathbf{x}^T \hat{\beta} \sim N\left(\mathbf{x}^T \beta, \mathbf{x}^T \text{Var}(\hat{\beta}) \mathbf{x}\right)$$

donde  $\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}^T \mathbf{X})^{-1}$

# Intervalos de Confianza

Intervalo de confianza para la media de  $Y$  dado  $X$

$$IC_{1-\alpha}(E(Y|X_1, \dots, X_k)) = \mathbf{x}^T \hat{\beta} \pm t_{gl_E; 1-\frac{\alpha}{2}} \sqrt{\mathbf{x}^T \hat{Var}(\hat{\beta}) \mathbf{x}}$$

Intervalos de predicción para  $Y$

$$IP_{1-\alpha}(E(Y|X_1, \dots, X_k)) = \mathbf{x}^T \hat{\beta} \pm t_{gl_E; 1-\frac{\alpha}{2}} \sqrt{\textcolor{red}{MSE} + \mathbf{x}^T \hat{Var}(\hat{\beta}) \mathbf{x}}$$

El significado de este intervalo es completamente diferente, dado que no se infiere sobre el valor de un parámetro (constante).

donde  $\hat{Var}(\hat{\beta}) = \text{MSE}(\mathbf{X}^T \mathbf{X})^{-1}$